Tuyệt vời! Đoạn output bạn cung cấp cho thấy UnstructuredLoader đã hoạt động thành công và trích xuất nội dung từ tệp PDF của bạn.

Các đối tượng Document được in ra, mỗi đối tượng chứa:

- **metadata**: Chứa thông tin chi tiết về đoạn văn bản được trích xuất, bao gồm:
    - source: Đường dẫn đến tệp PDF.
    - coordinates: Vị trí của đoạn văn bản trên trang (trong hệ thống PixelSpace).
    - file_directory, filename: Thông tin về tệp.
    - languages: Ngôn ngữ được phát hiện (ở đây là 'eng').
    - last_modified: Thời gian sửa đổi lần cuối của tệp.
    - page_number: Số trang mà đoạn văn bản được trích xuất từ đó.
    - filetype: Loại tệp (application/pdf).
    - category: Loại phần tử được unstructured phân loại (ví dụ: UncategorizedText, NarrativeText, Title, Footer).
    - element_id: Một ID duy nhất cho phần tử.
    - parent_id: Nếu là một phần tử con của một phần tử lớn hơn (ví dụ: một đoạn văn bản thuộc một tiêu đề).
    - links: (Trong một số trường hợp) Các liên kết được tìm thấy trong văn bản.
- **page_content**: Nội dung văn bản thực tế được trích xuất.

Quan sát và Lưu ý

Nhìn vào page_content của một số Document đầu tiên:

- page_content='3 2 0 2'
- page_content='g u A 2'
- page_content='] L C . s c ['
- page_content='7 v 2 6 7 3 0 . 6 0 7 1 : v i X r a'

Có vẻ như unstructured đang gặp một chút khó khăn trong việc trích xuất văn bản từ một số phần tử đầu tiên của tài liệu PDF AttentionIsAllYouNeed.pdf. Văn bản bị đảo ngược hoặc lộn xộn (3 2 0 2 thay vì 2023, g u A 2 thay vì Aug 2,] L C . s c [thay vì [cs.CL]). Điều này thường xảy ra với

các PDF có bố cục phức tạp, phông chữ nhúng đặc biệt, hoặc khi nội dung là hình ảnh (OCR được sử dụng, và OCR không hoàn hảo).

Tuy nhiên, các phần sau đó có vẻ tốt hơn:

- page_content='Attention Is All You Need' (Tiêu đề chính, được trích xuất chính xác)
- page_content='Ashish Vaswani∗ Google Brain avaswani@google.com' (Thông tin tác giả, được trích xuất chính xác)
- page_content='The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English- to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.' (Đoạn Abstract, trích xuất rất tốt)

Điều này có nghĩa là gì?

- **Bạn đã khắc phục được lỗi libmagic và pdfminer.six!** Đó là một thành công lớn.
- **UnstructuredLoader đang hoạt động.** Nó đã đọc tệp PDF và tạo ra các đối tượng Document.
- **Chất lượng trích xuất:** Đối với một số phần tử, chất lượng trích xuất không hoàn hảo. Điều này có thể chấp nhận được tùy thuộc vào ứng dụng của bạn. Nếu bạn cần trích xuất hoàn hảo từ mọi phần của PDF, bạn có thể cần:
    - **Tùy chỉnh UnstructuredLoader:** unstructured có rất nhiều tùy chọn để tinh chỉnh quá trình trích xuất (ví dụ: sử dụng các parsing strategy khác nhau, bật/tắt OCR, v.v.).
    - **Sử dụng các công cụ mạnh mẽ hơn:** Đối với các PDF phức tạp, đôi khi các công cụ OCR/trích xuất layout chuyên dụng hơn có thể cần thiết. docling mà bạn đã

hỏi ban đầu có vẻ là một công cụ mạnh mẽ hơn nhiều cho việc này, vì nó sử dụng VLM.

- **Tiền xử lý:** Nếu các ký tự bị đảo ngược liên tục, có thể cần một bước tiền xử lý để đảo ngược lại chúng.

Tiếp theo bạn có thể làm gì?

Bây giờ bạn đã có một danh sách các Document từ PDF, bạn có thể:

1. **Chuyển đổi thành chuỗi đơn:**

Generated python

full_text = "\n".join([doc.page_content for doc in docs])

print(full_text)

content_copydownload

Use code [with caution](#).Python

2. **Lọc hoặc xử lý các Document:**
    - Bạn có thể lọc các tài liệu dựa trên category (ví dụ: chỉ giữ lại NarrativeText).
    - Bạn có thể tiền xử lý page_content để cố gắng sửa các lỗi như ký tự đảo ngược (nếu nó là một lỗi có quy luật).
3. **Sử dụng chúng trong Langchain:** Các Document này sẵn sàng để được sử dụng trong các chuỗi xử lý Langchain tiếp theo, ví dụ như:
    - Tách đoạn (Text Splitting)
    - Tạo nhúng (Embeddings)
    - Tìm kiếm ngữ nghĩa (Semantic Search)
    - Tạo tóm tắt (Summarization)
    - RAG (Retrieval Augmented Generation)

Chúc mừng bạn đã giải quyết được các vấn đề cài đặt!